Рубежный контроль 1

Часть 1. Теоретические вопросы

1. Что такое разделяющая полоса (зазор, margin) и почему SVM максимизирует её ширину?

2. Что такое опорные векторы? Что произойдёт с моделью, если удалить объект, не являющийся опорным?

3. Чем SVM с жёстким зазором отличается от SVM с мягким зазором? Когда первый неприменим?

4. Какую роль играет параметр C? Что происходит при очень малом и очень большом C?

5. Объясните идею ядрового трюка. Зачем ядро, если можно явно добавить новые признаки?

6. Назовите основные ядра SVM и случаи, в которых каждое из них уместно.

7. Как параметр gamma RBF-ядра влияет на форму разделяющей границы? Как это связано с переобучением?

8. Почему перед обучением SVM обязательно масштабирование признаков? Как правильно его выполнять?

9. Как SVM решает многоклассовую задачу?

10. Почему SVM с ядром плохо масштабируется на большие выборки и что с этим делать?

11. Студент оставил в выборке только опорные векторы (удалил 90 % объектов) и переобучил тот же конвейер StandardScaler + SVC с теми же C и gamma. Граница получилась другой. Почему, ведь «решение зависит только от опорных векторов»?

12. «RBF-ядро соответствует бесконечномерному пространству признаков, поэтому SVM с RBF-ядром всегда лучше линейного». Верно ли это?

13. Обученный SVM оказался с опорными векторами, составляющими 98 % обучающей выборки. Хорошо это или плохо? О чём это говорит?

14. Сформулируйте теорему Байеса. Поясните смысл априорной вероятности, правдоподобия и апостериорной вероятности на инженерном примере.

15. Что такое оптимальный байесовский классификатор и почему его нельзя построить напрямую?

16. В чём состоит «наивное» предположение наивного Байеса? Почему метод работает, хотя оно почти никогда не выполняется?

17. Чем отличаются MultinomialNB, BernoulliNB, GaussianNB и ComplementNB? Для каких данных подходит каждый?

18. Зачем нужно сглаживание Лапласа? Что произойдёт без него?

19. Почему вероятности наивного Байеса плохо откалиброваны? Как это проверить и исправить?

20. Как учесть разную цену ошибок (например, пропуск отказа дороже ложной тревоги) при байесовском решении?

21. Чем LDA отличается от QDA? Какое предположение делает LDA и какую форму границы это даёт?

22. Чем генеративный подход к классификации отличается от дискриминативного? Когда наивный Байес выигрывает у логистической регрессии?

23. Что такое байесовская сеть? Для каких задач её строят вместо обучения классификатора?

24. Тест на неисправность детали обнаруживает 99 % неисправных и ошибочно бракует 5 % исправных. Неисправны 1 % деталей. Тест показал «неисправна». Какова вероятность, что деталь действительно неисправна?

25. Наивный Байес выдал для письма P(спам) = 0,9999. Студент утверждает: «модель практически уверена, ошибиться она не может». Прав ли он?

26. В таблицу данных по ошибке дважды добавили один и тот же датчик температуры. Как это повлияет на наивный Байес, LDA и логистическую регрессию?

27. Опишите устройство дерева решений: внутренние узлы, листья, предикаты. Что хранится в листе для классификации и для регрессии?

28. Как строится дерево решений (жадный рекурсивный алгоритм CART)? Почему не ищут оптимальное дерево целиком?

29. Что такое критерий неоднородности? Сравните индекс Джини и энтропию. Какой критерий используют в регрессии?

30. Что такое прирост (gain) и как выбирается лучшее разбиение в узле?

31. Почему глубокое дерево переобучается? Назовите способы контроля его сложности.

32. Почему дерево не умеет экстраполировать? Приведите инженерный пример, где это опасно.

33. Почему деревьям решений не нужно масштабирование признаков?

34. Что такое неустойчивость дерева? Как она проявляется и что с ней делают?

35. Почему дереву трудно описать наклонную границу, например $x_1 + x_2 > c$? Как ему помочь?

36. Назовите достоинства и недостатки деревьев решений. В каких инженерных задачах одно дерево — лучший выбор?

37. У признака «вибрация» встроенная важность в обученном дереве равна нулю. Студент делает вывод: «вибрация не связана с отказами». Прав ли он?

38. Дерево без каких-либо ограничений показало на обучающей выборке 97 % верных ответов, а не 100 %. Как это возможно, если «дерево без ограничений запоминает выборку»?

39. Классы устроены как XOR: класс 1 — если $x_1 > 0$ и $x_2 > 0$ либо $x_1 < 0$ и $x_2 < 0$, иначе класс 0; данные равномерно заполняют квадрат с центром в начале координат. Чему равен прирост Джини для разбиения $x_1 \le 0$ в корне? Что будет, если задать min_impurity_decrease = 0,01?

40. Что такое ансамбль моделей и при каких условиях он точнее отдельных моделей?

41. Объясните разложение ошибки на смещение и разброс. Что уменьшает бэггинг, а что — бустинг?

42. Что такое бутстреп и бэггинг? Почему в бутстреп-выборку попадает около 63 % различных объектов?

43. Что такое OOB-оценка качества? В каких случаях ей нельзя доверять?

44. Чем случайный лес отличается от бэггинга деревьев? Какую роль играет параметр max_features и почему деревья в лесу глубокие?

45. Опишите алгоритм градиентного бустинга. Почему он называется градиентным?

46. Зачем нужны темп обучения и ранняя остановка? Почему бустинг переобучается при росте числа деревьев, а случайный лес — нет?

47. Сравните библиотеки XGBoost, LightGBM, CatBoost и HistGradientBoosting.

48. Опишите стекинг. Зачем мета-модель обучают на out-of-fold прогнозах?

49. Как интерпретировать ансамбль деревьев? Сравните встроенную и перестановочную важность признаков, SHAP и суррогатное дерево.

50. Один студент обучил случайный лес из 1000 деревьев, другой — из 5000. Чей лес сильнее переобучен? А если бы это был градиентный бустинг без ранней остановки?

51. Студент собрал «ансамбль» из 10 моделей CatBoost с одинаковыми параметрами и одинаковым random_seed, обученных на одних и тех же данных, и усреднил их прогнозы. Какой выигрыш он получит?

52. Случайный лес, обученный на данных датчиков за январь–июнь (записи каждые 10 секунд), показал OOB-качество 0,95, а на данных июля — 0,70. В чём дело?

Часть 2. Тестовые вопросы

1. Опорными векторами называют:
а) все объекты обучающей выборки
б) объекты на границе полосы или нарушающие её
в) центры классов
г) объекты с наибольшими значениями признаков

2. Ширина разделяющей полосы линейного SVM равна:
а) $1/\|w\|$
б) $2/\|w\|$
в) $\|w\|$
г) $2\|w\|$

3. При увеличении C (остальное неизменно):
а) полоса становится шире, нарушений больше
б) штраф за нарушения растёт, полоса сужается, риск переобучения растёт
в) модель становится линейной
г) ничего не меняется

4. RBF-ядро записывается как:
а) x^Tz
б) $(x^Tz + 1)^d$
в) $\exp(-\gamma\|x - z\|^2)$
г) $\tanh(x^Tz)$

5. Очень большое значение gamma RBF-ядра приводит к:
а) почти линейной границе
б) извилистой границе с «островками» вокруг объектов и переобучению
в) недообучению
г) не влияет на границу

6. Функция потерь SVM (hinge loss) как функция отступа $M = y \cdot (w^Tx + b)$:
а) $\max(0, 1 - M)$
б) $\log(1 + e^{(-M)})$
в) $(1 - M)^2$
г) $e^{(-M)}$

7. Признаки «зарплата, руб.» и «стаж, лет» поданы в SVM с RBF-ядром без масштабирования. Что произойдёт?
а) ничего особенного
б) расстояние почти целиком определяется зарплатой, стаж фактически игнорируется
в) доминировать будет стаж
г) обучение не запустится

8. Классификация текстов: 100 000 признаков (мешок слов), 1 млн документов. Лучший выбор:

а) SVC с RBF-ядром

б) линейный SVM (LinearSVC)

в) SVC с полиномиальным ядром степени 5

г) метод k ближайших соседей

9. SVC(probability=True) в scikit-learn получает вероятности классов:

а) напрямую из расстояния до границы

б) калибровкой Платта — логистической регрессией на значениях решающей функции с кросс-валидацией

в) по доле опорных векторов

г) не умеет выдавать вероятности

10. В регрессии на опорных векторах (SVR) объекты внутри ε-трубки:

а) штрафуются квадратично

б) не штрафуются

в) удаляются из выборки

г) становятся опорными векторами

11. (несколько ответов) Какие утверждения о SVM верны?

а) решение зависит только от опорных векторов

б) задача обучения выпуклая, глобальный оптимум единственный

в) по умолчанию выдаёт откалиброванные вероятности

г) чувствителен к масштабу признаков

д) не требует настройки гиперпараметров

12. (несколько ответов) Какие функции являются допустимыми ядрами?

а) $K(x, z) = x^T z$

б) $K(x, z) = (x^T z + 1)^2$

в) $K(x, z) = \exp(-\gamma\|x - z\|^2)$, $\gamma > 0$

г) $K(x, z) = x_1 \cdot z_2$ (первый признак одного объекта, умноженный на второй признак другого)

д) $K(x, z) = -x^T z$

13. (несколько ответов) Признаки переобучения SVM с RBF-ядром:

а) очень большие значения C и gamma

б) 100 % верных ответов на обучении и заметно меньше на валидации

в) граница почти прямая

г) «островки» своего класса вокруг отдельных объектов

д) очень малое значение C

14. (несколько ответов) SVC с RBF-ядром на 2 млн объектов обучается слишком долго. Что поможет?

а) перейти на LinearSVC

б) SGDClassifier с hinge-потерей
в) аппроксимация ядра (Nystroem, RBFSampler) + линейный SVM
г) увеличить C до 10^6
д) отказаться от масштабирования признаков

15. (несколько ответов) Для каких задач SVM — разумный выбор?
а) классификация текстов по TF-IDF
б) сотни–тысячи объектов при большом числе признаков
в) таблица на 10 млн строк с категориальными признаками
г) нужны понятные правила для регулятора
д) поиск аномалий (One-Class SVM)

16. (несколько ответов) Верно о параметре C:
а) это коэффициент штрафа за нарушения зазора
б) $C \to \infty$ приближает к жёсткому зазору
в) подбирается по кросс-валидации, обычно по логарифмической сетке
г) $C = 0$ — оптимальное значение
д) C влияет только при RBF-ядре

17. (несколько ответов) Многоклассовая классификация с SVM:
а) one-vs-rest обучает K классификаторов
б) one-vs-one обучает $K(K-1)/2$ классификаторов
в) SVC в scikit-learn внутри использует one-vs-one
г) SVM изначально многоклассовый и не нуждается в таких схемах
д) при 10 классах one-vs-one обучает 10 моделей

18. (несколько ответов) Отступ объекта $M_i = y_i(w^T x_i + b)$. Верно:
а) $M > 1$ — объект классифицирован верно и лежит вне полосы
б) $0 < M < 1$ — верно, но внутри полосы
в) $M < 0$ — ошибка классификации
г) $M = 1$ — объект на границе полосы
д) объекты с $M < 0$ не штрафуются

19. (несколько ответов) О масштабировании признаков:
а) StandardScaler обучается только на обучающей выборке
б) скейлер помещают в Pipeline вместе с моделью, чтобы не было утечки при кросс-валидации
в) для деревьев решений масштабирование тоже обязательно
г) без масштабирования признак с большим разбросом доминирует в RBF-расстоянии
д) масштабирование меняет метки классов

20. (несколько ответов) Сравнение SVM и логистической регрессии:
а) с линейным ядром оба метода — линейные классификаторы
б) логистическая регрессия естественно выдаёт вероятности, SVM — нет

в) hinge-потеря равна нулю при отступе ≥ 1, логистическая потеря не равна нулю никогда
г) SVM всегда точнее
д) логистическая регрессия не допускает регуляризации

21. Теорема Байеса:
а) $P(A \mid B) = P(B \mid A) \cdot P(A) / P(B)$
б) $P(A \mid B) = P(A) \cdot P(B)$
в) $P(A \mid B) = P(B \mid A)$
г) $P(A \mid B) = P(A) + P(B) - P(AB)$

22. «Наивное» предположение наивного Байеса:
а) классы равновероятны
б) признаки условно независимы при известном классе
в) признаки распределены нормально
г) признаки независимы безусловно

23. Для «мешка слов» со счётчиками слов естественнее всего использовать:
а) GaussianNB
б) MultinomialNB
в) BernoulliNB
г) QDA

24. Слово ни разу не встречалось в спам-письмах обучающей выборки. Без сглаживания наивный Байес для нового письма с этим словом даст P(спам | письмо), равную:
а) 0
б) 0,5
в) 1
г) неопределённости

25. LDA предполагает:
а) нормальные распределения классов с общей ковариационной матрицей
б) независимость признаков
в) равные априорные вероятности классов
г) разные ковариационные матрицы у классов

26. Граница между классами в QDA:
а) линейная
б) квадратичная
в) кусочно-постоянная
г) всегда окружность

27. Максимальное число компонент LDA при снижении размерности для 3 классов и 13 признаков:

а) 13
б) 3
в) 2
г) 12

28. Почему QDA на маленькой выборке часто работает хуже LDA?
а) нужно оценить отдельную ковариационную матрицу для каждого класса — слишком много параметров
б) QDA не умеет работать более чем с двумя классами
в) QDA — линейный метод
г) QDA не использует априорные вероятности

29. Цены ошибок одинаковы, вероятности откалиброваны. Оптимальный порог на P(отказ | x) для решения «отказ»:
а) доля отказов в обучающей выборке
б) 0,5
в) 0,99
г) 0,1

30. Пропуск отказа стоит 90 тыс. руб., ложная тревога — 10 тыс. руб. Оптимальный порог на P(отказ | x):
а) 0,5
б) 0,1
в) 0,9
г) 0,01

31. (несколько ответов) Достоинства наивного Байеса:
а) очень быстрое обучение (один проход по данным)
б) хорошо работает при малом объёме данных и большом числе признаков
в) хорошо откалиброванные вероятности
г) легко дообучается на новых данных (partial_fit)
д) учитывает взаимодействия признаков

32. (несколько ответов) Какие модели относятся к генеративным?
а) наивный Байес
б) LDA
в) QDA
г) логистическая регрессия
д) SVM

33. (несколько ответов) Сглаживание Лапласа:
а) добавляет α к каждому счётчику
б) предотвращает нулевые вероятности
в) α — гиперпараметр, подбирается на валидации
г) увеличивает число признаков

д) нужно только для GaussianNB

34. (несколько ответов) В данные дважды попал один и тот же признак. Что произойдёт с наивным Байесом?

а) признак учтётся дважды, вероятности станут экстремальнее

б) вырастет переуверенность (вероятности ближе к 0 и 1)

в) модель перестанет обучаться

г) ранжирование объектов может остаться разумным

д) модель автоматически удалит дубликат

35. (несколько ответов) Про калибровку вероятностей верно:

а) её проверяют калибровочной кривой (reliability diagram)

б) исправляют методом Платта или изотонической регрессией (CalibratedClassifierCV)

в) калибровка Платта меняет порядок объектов по вероятности

г) Brier score отражает качество вероятностей

д) калибровку обучают на той же тестовой выборке, на которой затем оценивают модель

36. (несколько ответов) Про LDA верно:

а) граница между классами линейная

б) можно использовать для снижения размерности с учётом меток классов

в) предполагается общая ковариация классов

г) при p > n ковариационная матрица вырождена и нужна регуляризация (shrinkage)

д) граница всегда нелинейная

37. (несколько ответов) Когда наивный Байес — более разумный выбор, чем логистическая регрессия?

а) обучающая выборка очень маленькая

б) нужно очень быстро обучаться на потоке данных

в) выборка огромная, признаки сильно зависимы

г) много признаков и мало объектов (тексты)

д) нужны точные вероятности для расчёта страховых сумм

38. (несколько ответов) Про байесовскую сеть верно:

а) это направленный ациклический граф

б) каждой вершине сопоставлена таблица условных вероятностей при значениях родителей

в) позволяет вычислить вероятность причины по наблюдаемым симптомам

г) структура может задаваться экспертом

д) обязательно содержит циклы обратной связи

39. (несколько ответов) Две независимые причины A и B (износ подшипника и расцентровка) вызывают общее следствие C (вибрацию). Верно:

а) без наблюдений A и B независимы
б) при наблюдении C они становятся зависимыми
в) если C наблюдается и B подтверждена, вероятность A снижается
г) наблюдение C делает A и B независимыми
д) этот эффект возникает только в наивном Байесе

40. (несколько ответов) Про GaussianNB верно:
а) для каждого класса и признака оцениваются среднее и дисперсия
б) ковариации между признаками не учитываются
в) это частный случай QDA с диагональными ковариационными матрицами
г) работает только с бинарными признаками
д) граница между классами всегда линейная

41. Индекс Джини для двух классов с долей класса 1, равной p:
а) $p(1 - p)$
б) $2p(1 - p)$
в) $-p \cdot \log_2 p$
г) $1 - p^2$

42. Максимальное значение индекса Джини для двух классов:
а) 1
б) 0,5
в) 0,25
г) ln 2

43. Энтропия (по основанию 2) узла с равными долями двух классов:
а) 0
б) 0,5
в) 1
г) 2

44. Прогноз в листе регрессионного дерева с критерием MSE — это:
а) медиана целевой переменной в листе
б) среднее значение целевой переменной в листе
в) мода
г) максимум

45. Какой параметр НЕ ограничивает сложность дерева?
а) max_depth
б) min_samples_leaf
в) criterion
г) max_leaf_nodes

46. Регрессионное дерево обучено на температурах 20–80 °C, целевая величина растёт с температурой линейно. Прогноз при 120 °C:

а) продолжит линейный рост
б) будет примерно равен прогнозу при 80 °C
в) будет равен нулю
г) модель выдаст ошибку

47. Бинарное дерево глубины d имеет не более:
а) d листьев
б) 2d листьев
в) 2^d листьев
г) d^2 листьев

48. Признак принимает 1000 различных значений. Сколько порогов по нему проверяет CART в одном узле (в худшем случае)?
а) 1000
б) 999
в) 500
г) 2^1000

49. При увеличении параметра стрижки ccp_alpha:
а) дерево становится глубже
б) число листьев уменьшается
в) дерево не меняется
г) меняется только критерий разбиения

50. Какое преобразование признака может изменить структуру дерева (а не только значения порогов)?
а) логарифм
б) умножение на 1000
в) стандартизация
г) замена x на $(x - 5)^2$

51. (несколько ответов) Верно о деревьях решений:
а) не требуют масштабирования признаков
б) работают с признаками разной природы и единиц измерения
в) при малой глубине дают интерпретируемые правила
г) строят гладкую границу между классами
д) хорошо экстраполируют

52. (несколько ответов) Признаки переобучения дерева:
а) 100 % верных ответов на обучении и заметно меньше на тесте
б) много листьев с одним-двумя объектами
в) очень большая глубина
г) max_depth = 2
д) одинаковое качество на обучении и тесте

53. (несколько ответов) Способы борьбы с переобучением дерева:

а) ограничить max_depth

б) увеличить min_samples_leaf

в) стрижка с параметром ccp_alpha

г) перейти к ансамблю деревьев

д) убрать все ограничения на глубину

54. (несколько ответов) Критерии разбиения для классификационного дерева в scikit-learn:

а) индекс Джини

б) энтропия

в) MSE

г) MAE

д) коэффициент детерминации R^2

55. (несколько ответов) О жадности алгоритма построения дерева:

а) на каждом шаге выбирается лучшее разбиение без учёта следующих шагов

б) поиск глобально оптимального дерева — вычислительно трудная (NP-трудная) задача

в) жадность гарантирует оптимальное дерево

г) из-за жадности XOR-подобная зависимость может не найтись на первом шаге

д) жадность устраняет переобучение

56. (несколько ответов) Неустойчивость дерева решений:

а) небольшое изменение выборки может сменить признак в корне

б) это проявление большого разброса модели

в) лечится усреднением многих деревьев

г) лечится увеличением глубины

д) свойственна только регрессионным деревьям

57. (несколько ответов) В каких ситуациях одиночное дерево — уместный выбор?

а) регламент действий оператора

б) объяснение решения регулятору

в) прогноз на микроконтроллере с жёсткими ограничениями

г) прогноз в режимах, которых не было в обучающих данных

д) распознавание изображений

58. (несколько ответов) Об энтропии верно:

а) равна 0 для чистого узла

б) максимальна при равномерном распределении классов

в) может быть отрицательной

г) для четырёх равновероятных классов равна 2 битам

д) всегда не превышает 1

59. (несколько ответов) О регрессионном дереве CART верно:

а) прогноз — кусочно-постоянная функция

б) разбиение выбирается по уменьшению MSE

в) прогноз лежит в пределах значений y обучающей выборки

г) может предсказать значение больше максимального y

д) в каждом листе хранится линейная модель

60. (несколько ответов) Классы разделены прямой $x_1 + x_2 = 10$. Верно:

а) дерево приблизит границу «лесенкой»

б) потребуется много разбиений

в) после добавления признака $x_1 + x_2$ хватит одного разбиения

г) дерево найдёт границу одним разбиением по исходным признакам

д) масштабирование признаков решит проблему

61. Доля различных объектов исходной выборки в бутстреп-выборке при большом n:

а) 50 %

б) ≈ 63,2 %

в) ≈ 36,8 %

г) 100 %

62. Три независимых классификатора ошибаются с вероятностью 0,2 и голосуют большинством. Вероятность ошибки ансамбля:

а) 0,2

б) 0,104

в) 0,008

г) 0,6

63. Бэггинг уменьшает в первую очередь:

а) смещение

б) разброс

в) шум в данных

г) время обучения

64. Значение max_features по умолчанию в RandomForestClassifier:

а) все признаки

б) $\sqrt{p}$

в) $p/3$

г) $\log_2 p$

65. Если в случайном лесе задать max_features равным числу всех признаков, получится:

а) градиентный бустинг

б) бэггинг деревьев

в) одно дерево

г) ExtraTrees

66. В градиентном бустинге с квадратичной функцией потерь очередное дерево обучается на:

а) исходных метках y

б) остатках $y - a(x)$

в) бутстреп-выборке исходных меток

г) квадратах остатков

67. Типичная глубина деревьев в градиентном бустинге:

а) 1

б) 3–6

в) 20–30

г) без ограничений

68. Российская библиотека градиентного бустинга со встроенной обработкой категориальных признаков и симметричными деревьями:

а) XGBoost

б) LightGBM

в) CatBoost

г) HistGradientBoosting

69. В смеси экспертов, в отличие от стекинга, вес каждой модели:

а) одинаков для всех объектов

б) зависит от входного объекта

в) всегда равен 1/M, где M — число экспертов

г) задаётся вручную человеком-экспертом

70. Доля отказов в данных — 4 %. Какая метрика лучше всего подходит для сравнения моделей?

а) accuracy

б) PR-AUC

в) MSE

г) R^2

71. (несколько ответов) Условия эффективности ансамбля:

а) каждая модель лучше случайного угадывания

б) ошибки моделей слабо коррелированы

в) все модели одинаковы

г) модели разнообразны

д) каждая модель безошибочна

72. (несколько ответов) Верно о случайном лесе:

а) рост числа деревьев не ухудшает качество на тесте

б) деревья можно обучать параллельно

в) есть OOB-оценка без отложенной выборки
г) на обучающей выборке качество обычно близко к 100 %
д) лес умеет экстраполировать

73. (несколько ответов) Верно о градиентном бустинге:
а) деревья строятся последовательно
б) уменьшает прежде всего смещение
в) без ранней остановки может переобучиться
г) при меньшем темпе обучения требуется больше деревьев
д) деревья независимы друг от друга

74. (несколько ответов) Способы борьбы с переобучением бустинга:
а) уменьшить темп обучения
б) ранняя остановка по валидационной выборке
в) ограничить глубину деревьев
г) обучать каждое дерево на случайной подвыборке (subsample)
д) увеличить число деревьев без контроля на валидации

75. (несколько ответов) Как включить раннюю остановку в библиотеках бустинга:
а) параметр early_stopping_rounds в XGBoost и CatBoost
б) callback early_stopping в LightGBM
в) early_stopping=True в HistGradientBoosting
г) параметр max_features
д) параметр oob_score=True

76. (несколько ответов) Правильная практика стекинга:
а) мета-модель обучается на out-of-fold прогнозах
б) мета-модель обычно простая
в) допустим блендинг на отдельной отложенной выборке
г) мета-модель обучается на прогнозах для тех же объектов, на которых учились базовые модели
д) лучшие базовые модели — одинаковые модели с одинаковыми параметрами

77. (несколько ответов) Об интерпретации ансамблей верно:
а) встроенная важность смещена в пользу признаков со многими различными значениями
б) перестановочную важность считают на отложенных данных
в) SHAP раскладывает каждый прогноз на вклады признаков
г) 98 % совпадения суррогатного дерева с моделью гарантирует надёжность объяснения
д) для деревьев SHAP считается точно и быстро (TreeExplainer)

78. (несколько ответов) Бэггинг заметно улучшит:

а) глубокое дерево решений
б) метод k ближайших соседей с k = 1
в) линейную регрессию
г) метод k ближайших соседей с k = 100
д) любую неустойчивую модель с большим разбросом

79. (несколько ответов) Отличия случайного леса от градиентного бустинга:
а) в лесу деревья глубокие, в бустинге мелкие
б) лес строится параллельно
в) бустинг чувствительнее к шуму в метках
г) лес требует более тщательной настройки
д) бустинг неприменим для регрессии

80. (несколько ответов) Где сегодня используются идеи ансамблей?
а) в языковых моделях с архитектурой смеси экспертов (Mixtral, DeepSeek)
б) в AutoML-системах
в) в поиске аномалий методом Isolation Forest
г) в соревнованиях по табличным данным
д) только в классификации изображений

Часть 3. Практические задачи

1. Линейный классификатор: $w = (2, -1)$, $b = -1$. Объекты: A(1, 0), y = +1; B(0, 1), y = −1; C(2, 2), y = −1. Для каждого найдите значение решающей функции $f(x) = w^T x + b$, прогноз класса, отступ $M = y \cdot f(x)$ и hinge-потерю $\max(0, 1 - M)$. Какие объекты являются опорными?

2. У линейного SVM вектор весов $w = (3, 4)$. Найдите ширину разделяющей полосы.

3. Одномерная задача. Класс −1: x = 1; 2. Класс +1: x = 4; 6. Найдите границу SVM с жёстким зазором, опорные векторы, ширину полосы, а также w и b (границы полосы: $w \cdot x + b = \pm 1$).

4. RBF-ядро $K(x, z) = \exp(-\gamma \|x - z\|^2)$, $\gamma = 0{,}5$. Вычислите K(x, z) для x = (1, 2), z = (2, 4) и для x = (1, 2), z′ = (1; 2,5). Справка: e^(−2,5) ≈ 0,082; e^(−0,125) ≈ 0,882. Какой из объектов сильнее «похож» на x?

5. Покажите, что ядро $K(x, z) = (x^T z)^2$ для двумерных векторов соответствует отображению $\varphi(x) = (x_1^2, \sqrt{2} \cdot x_1 x_2, x_2^2)$. Проверьте на x = (1, 2), z = (3, 1).

6. Сколько бинарных классификаторов потребуется для 6 классов по схеме one-vs-rest и по схеме one-vs-one? Одна модель на всех данных обучается 10 с, время обучения растёт квадратично с объёмом выборки, классы одинакового размера. Какая схема быстрее?

7. SVM с линейным ядром задан двумя опорными векторами: $x_1 = (1, 1)$, $y_1 = +1$, $a_1 = 0{,}5$; $x_2 = (-1, -1)$, $y_2 = -1$, $a_2 = 0{,}5$; $b = 0$. Решающая функция $f(x) = \Sigma\, a_i y_i K(x_i, x) + b$. Классифицируйте объекты (2, 0) и (0,5; −1) и найдите вектор $w = \Sigma\, a_i y_i x_i$.

8. Детали поступают со станка A (60 %) и станка B (40 %). Доля брака у A — 2 %, у B — 5 %. Найдите вероятность брака у случайной детали и вероятность того, что бракованная деталь сделана на станке B.

9. Обучающая выборка — 10 писем: 4 спама и 6 обычных. Слово «скидка» встречается в 3 из 4 спам-писем и в 1 из 6 обычных; слово «отчёт» — в 1 из 4 спам-писем и в 4 из 6 обычных. Новое письмо содержит слово «скидка» и не содержит слова «отчёт». Используя бернуллиевский наивный Байес без сглаживания, найдите P(спам | письмо).

10. MultinomialNB. В спам-письмах обучающей выборки суммарно 20 слов, словарь состоит из 8 слов. Слово «кредит» в спаме не встречалось, слово «бесплатно» встретилось 4 раза. Найдите P(кредит | спам) и P(бесплатно | спам) без сглаживания и со сглаживанием Лапласа $a = 1$: $P = (n + a) / (N + a \cdot V)$, где V — размер словаря.

11. Пропуск отказа обходится в 50 000 руб., ложная остановка станка — в 5 000 руб. Модель выдала P(отказ) = 0,2. Останавливать ли станок? Каков оптимальный порог вероятности?

12. Одномерная LDA: два класса с нормальными распределениями, общая дисперсия $\sigma^2 = 1$, средние $\mu_0 = 2$ и $\mu_1 = 6$. а) Найдите границу при равных априорных вероятностях. б) Найдите границу, если P(класс 1) = 0,2. Формула: $x^* = (\mu_0 + \mu_1)/2 + \sigma^2/(\mu_1 - \mu_0) \cdot \ln(P_0/P_1)$; ln 4 ≈ 1,386. Куда сдвинулась граница и почему?

13. Байесовская сеть из двух вершин: износ подшипника B (априорная вероятность 0,1) → вибрация V. P(V | B) = 0,8, P(V | не B) = 0,1. Зафиксирована вибрация. Найдите P(B | V).

14. В узле 30 объектов класса 1 и 10 объектов класса 0. Найдите индекс Джини и энтропию узла. Справка: $\log_2 0{,}75 \approx -0{,}415$.

15. В узле 40 объектов: 20 исправных и 20 отказов. Разбиение A делит их на (15 исправных, 5 отказов) и (5, 15). Разбиение B — на (20, 10) и (0, 10). Какое разбиение выберет дерево по критерию Джини? Приведите расчёт прироста.

16. Регрессия: x = 1, 2, 3, 4, 5; y = 2, 4, 4, 10, 12. Найдите лучший первый порог по сумме квадратов отклонений от средних в листьях среди порогов 1,5; 2,5; 3,5; 4,5. Какие прогнозы будут в листьях? Что дерево предскажет для x = 100?

17. Дерево диагностики станка: (1) если мощность P < 3500 Вт или P > 9000 Вт → отказ; (2) иначе, если ΔT ≤ 8,6 K и скорость < 1380 об/мин → отказ; (3) иначе → норма. Мощность $P = M \cdot n \cdot 2\pi/60 \approx 0{,}105 \cdot M \cdot n$ (M — крутящий момент, Н·м; n — скорость, об/мин). Классифицируйте детали: №1 — M = 40, n = 1500, ΔT = 9,5; №2 — M = 70, n = 1400, ΔT = 10; №3 — M = 30, n = 1300, ΔT = 8,0.

18. а) Каково максимальное число листьев и внутренних узлов у бинарного дерева глубины 4? б) В выборке 500 объектов, задано min_samples_leaf = 50. Какое наибольшее число листьев возможно?

19. Стрижка по критерию стоимости-сложности: $R_\alpha(T) = R(T) + \alpha \cdot |T|$, где R — ошибка дерева, |T| — число листьев. Дерево T_1: ошибка 0,10, 8 листьев. Дерево T_2: ошибка 0,14, 3 листа. При каком α деревья равноценны? Какое дерево будет выбрано при α = 0,01?

20. Пять независимых классификаторов ошибаются с вероятностью 0,2 каждый и голосуют большинством. Найдите вероятность ошибки ансамбля.

21. Выборка из трёх объектов {A, B, C}. Делается бутстреп-выборка размера 3. а) Какова вероятность, что объект A не попадёт в неё? б) Каково ожидаемое число различных объектов в бутстреп-выборке? Сравните с предельным значением 63,2 %.

22. Износ трёх резцов: x = 1, 2, 3 (номер смены), y = 3, 5, 10 мкм. Выполните один шаг градиентного бустинга с квадратичной функцией потерь: а) найдите начальный прогноз и остатки; б) дерево глубины 1 выбирает порог 1,5 или 2,5 по минимуму суммы квадратов отклонений остатков от средних в листьях — какой порог и какие значения в листьях; в) найдите новый прогноз при η = 0,5; г) сравните MSE до и после шага.

23. Случайный лес из четырёх деревьев обучен на четырёх объектах с истинными метками $y_1 = 1$, $y_2 = 0$, $y_3 = 1$, $y_4 = 0$. Бутстреп-выборки (номера объектов): дерево 1 — {1, 2, 2, 3}; дерево 2 — {1, 1, 3, 4}; дерево 3 — {2, 3, 4, 4}; дерево 4 — {1, 2, 4, 4}. Прогнозы деревьев для объектов, которых они не видели: дерево 1 → 1, дерево 2 → 0, дерево 3 → 1, дерево 4 → 0. Определите OOB-объекты каждого дерева и найдите OOB-долю верных ответов.

24. Каждая из n моделей ансамбля имеет дисперсию прогноза $\sigma^2 = 4$, корреляция прогнозов любых двух моделей — ρ. Дисперсия среднего прогноза: $\rho\sigma^2 + (1 - \rho)\sigma^2/n$. Найдите её для n = 10 при ρ = 0 и ρ = 0,5. Что будет при $n \to \infty$? Какой вывод из этого следует для случайного леса?

25. Смесь двух экспертов прогнозирует амплитуду вибрации. Эксперт 1 (обучен на режимах пуска) даёт 100 мкм, эксперт 2 (номинальный режим) — 300 мкм. Для объекта A функция компетентности даёт веса (0,8; 0,2), для объекта B — (0,1; 0,9). Найдите прогнозы и сравните с простым усреднением с равными весами.

26. Модель отказов на тестовой выборке имеет PR-AUC 0,85. После случайного перемешивания отдельных признаков PR-AUC стала: «Момент» — 0,40; «Износ» — 0,70; «Тип станка» — 0,84; «Номер детали» — 0,86. Найдите перестановочную важность каждого признака, упорядочьте признаки и объясните, что означает отрицательное значение.